

UNIVERSIDAD DEL VALLE DE GUATEMALA

CC3084 - Data Science

Sección 40

Ing. Erick Marroquín



Laboratorio 1

Bryan Alberto Martínez Orellana 23542

Adriana Sophia Palacios Contreras 23044

Javier Andrés Benítez García 23405

GUATEMALA

26 de julio de 2026

Introducción

El presente informe reúne el análisis de series de tiempo realizado sobre el ingreso de viajeros internacionales a Guatemala, a partir de datos mensuales de migración que abarcan de enero de 2009 a junio de 2026. El objetivo es caracterizar el comportamiento del turismo (tendencia, estacionalidad y estacionariedad), modelar varias series mensuales para predecir su comportamiento, y comparar las series entre sí para identificar patrones relevantes.

Antes de modelar, se tomaron dos decisiones de preparación que atraviesan todo el trabajo:

- **Filtro de categorías consistentes.** Entre 2022 y 2023 el tipo de viajero cambió de criterio y la categoría "Viajero" cae fuertemente por un cambio metodológico, no por una caída real de turismo. Para poder comparar de forma consistente en todo el período, se conservan únicamente Turista + Excursionista, que mantienen la misma definición a lo largo de toda la serie.
- **Partición temporal 70/30.** Al tratarse de series de tiempo, la división en entrenamiento y prueba se hizo respetando el orden cronológico, no de forma aleatoria.

Tabla 1. Partición de los datos (70/30 temporal)

Conjunto	Rango	Meses	Filas
Entrenamiento	2009-01 - 2021-03	147 (70%)	116,966
Prueba	2021-04 - 2026-06	63 (30%)	20,676

Análisis exploratorio de datos

El dataset cubre 210 meses consecutivos sin huecos (161,036 registros en formato largo). Los hallazgos principales del EDA fueron los siguientes:

- **Calidad de datos.** No se encontraron valores faltantes explícitos ni disfrazados, ni filas 100% duplicadas. Los 22 "duplicados parciales" detectados en realidad difieren en la columna Agrupación Residencia, es decir, no son duplicados sino un mayor nivel de detalle.

- **Valores atípicos.** Bajo el criterio del rango intercuartílico, alrededor del 16.39% de los registros son atípicos, pero estos concentran el 96.68% del total de viajeros. Es decir, no son errores, sino los flujos legítimos de mayor volumen; por ello no se eliminan.
- **Quiebres a considerar.** La pandemia (colapso 2020–2021) y el quiebre metodológico 2022→2023 de la categoría "Viajero".

Tabla 2. Vías de ingreso y fronteras más utilizadas (por total de viajeros)


Vía	% viajeros	Frontera principal	% viajeros
Terrestre	61.19%	01 La Aurora	36.40%
Aérea	36.46%	07 Valle Nuevo	20.53%
Marítima	2.35%	09 San Cristóbal	10.26%

La vía terrestre concentra la mayor parte del flujo, mientras que casi todo el flujo aéreo entra por La Aurora, el único aeropuerto principal del país. A nivel temporal, el turismo creció de forma sostenida de 2009 a 2019, colapsó con la pandemia (piso en mayo 2020) y se recuperó a partir de 2022, aunque sin alcanzar todavía el pico de 2019.

Modelado de las series de tiempo

Se modelaron cuatro series mensuales: la serie obligatoria (total mensual de viajeros) y las tres regiones que más viajeros aportan según la variable Región dos (América del Centro, América del Norte y Europa). Cada serie se analizó de punta a punta con el mismo flujo: inicio/fin/frecuencia, gráfico, descomposición, transformación, estacionariedad (ACF + Dickey-Fuller Aumentada), elección de parámetros SARIMA a partir de ACF/PACF, comparación de modelos y predicción.

En todos los casos se aplicó transformación logarítmica (por la varianza que crece con el nivel) y una diferencia regular más una estacional ($d=1$, $D=1$) para alcanzar la estacionariedad. Se ajustaron dos modelos SARIMA por serie (uno leído de la ACF/PACF y otro obtenido por búsqueda de AIC) y se compararon contra Holt-Winters, suavizamiento exponencial simple, seasonal naive y Prophet.



Descomposición multiplicativa — Total de viajeros





Tabla 3. Resumen del modelado por serie

Serie	Transformación	SARIMA (mejor por AIC/BIC)	Mejor modelo (prueba)	MAE	RMSE
Total mensual	log	(0,1,0)(1,1,0)[12]	Suav. exp. simple	158,777	173,709

América del Centro	log	(0,1,0)(1,1,0)[12]	Suav. exp. simple	108,285	120,341
América del Norte	log	(2,1,2)(1,1,1)[12]	Suav. exp. simple	32,194	36,725
Europa	log	(2,1,2)(0,1,1)[12]	Suav. exp. simple	9,292	10,695
01 La Aurora	log	(2,1,2)(1,0,1)[12]	Suav. exp. simple	36,822	42,053
07 Valle Nuevo	ninguna	(0,1,0)(0,1,1)[12]	Prophet	16,804	23,187
09 San Cristóbal	log	(1,2,1)(1,1,0)[12]	Suav. exp. simple	21,103	23,740

Hallazgo transversal. En casi todas las series el mejor modelo fue el suavizamiento exponencial simple, por encima de los modelos SARIMA y de Prophet. Esto se debe a que el entrenamiento termina justo en el desplome de la pandemia: los modelos que aprenden la tendencia proyectan esa caída hacia adelante, mientras que un modelo más simple se mantiene en un nivel más estable y se acerca más a los valores reales de la recuperación. Como consecuencia, todas las predicciones subestiman la recuperación real (por ejemplo, para el total el modelo proyecta ~1.02 millones de viajeros al año, frente a los ~3.2 millones reales).

	MAE	RMSE
Suav. exp. simple	158777.0	173709.0
Holt-Winters	178392.0	192825.0
Seasonal naive	207322.0	219664.0
SARIMA (Modelo 2)	228181.0	244059.0
Prophet	233092.0	246956.0



Notas por serie. El total mensual y América del Centro se comportan de forma limpia y muy similar. América del Norte y Europa presentaron dos particularidades: en Norteamérica el relleno de los meses de cierre pandémico distorsionó la prueba ADF (la serie parecía estacionaria sin diferenciar, pero la tendencia y el ACF indicaban lo contrario), y en Europa el colapso fue tan severo (de ~16 mil a 22 viajeros) que fue la serie más difícil de estabilizar.

Análisis comparativo

Regiones


Las comparaciones de estacionalidad, crecimiento y volatilidad se hicieron sobre el período previo a la pandemia (2009–2019) para medir el comportamiento normal de cada serie, mientras que el impacto de la pandemia se midió sobre el desplome de 2020.

Tabla 4. Comparativo de las regiones

Región	ACF mes 12 (estacionalidad)	Crecimiento 2009–2019	CV (volatilidad)	Caída pandemia
América del	0.55	155%	0.36	96.4%

Centro				
América del Norte	0.79	45%	0.24	97.7%
Europa	0.80	26%	0.25	99.8%

- **Mayor estacionalidad:** Europa (0.80), prácticamente empatada con América del Norte (0.79); ambas más estacionales que América del Centro.
- **Mayor tendencia de crecimiento:** América del Centro (155%), muy por encima de las demás.
- **Mayor volatilidad (coeficiente de variación):** América del Centro (0.36); este valor alto se explica por su fuerte crecimiento, que dispersa más sus valores respecto a la media, no por cambios bruscos mes a mes.
- **Más afectada por la pandemia:** Europa (99.8% de caída, hasta 22 viajeros).



Fronteras

Se comparan las tres fronteras principales por total acumulado de viajeros (01 La Aurora, 07 Valle Nuevo y 09 San Cristóbal), con las mismas medidas y sobre los mismos períodos que las regiones.

Tabla 5. Comparativo de las fronteras

Frontera	ACF mes 12	Crecimiento 2009-2019	CV	Caída pandemia
01 La Aurora	0.77	59%	0.22	99.6%
07 Valle Nuevo	0.49	152%	0.40	99.9%
09 San Cristóbal	0.35	238%	0.52	100.0%

- **Mayor estacionalidad:** La Aurora (0.77), muy por encima de las fronteras terrestres. Tiene sentido, ya que es el aeropuerto y el turismo aéreo se concentra en temporadas específicas, mientras que las fronteras terrestres reciben un flujo más constante (comercio, visitas familiares) que diluye el patrón estacional.
 - **Mayor tendencia de crecimiento:** San Cristóbal (238%), seguida de Valle Nuevo (152%) y La Aurora (59%). Esto se explica porque San Cristóbal parte de una base mucho menor, por lo que un mismo incremento absoluto representa un porcentaje de crecimiento mayor; en volumen absoluto, La Aurora sigue siendo la más grande.
 - **Mayor volatilidad (coeficiente de variación):** San Cristóbal (0.52); el orden coincide con el del crecimiento, ya que la frontera que más creció porcentualmente es también la que más dispersa sus valores respecto a la media.
 - **Más afectada por la pandemia:** Las tres prácticamente se anulan (99.6%, 99.9% y 100.0%). A diferencia de las regiones, aquí casi no hay diferencia, ya que el cierre fue una decisión nacional única que afectó por igual a la vía aérea y a la terrestre.
-

Recomendaciones para INGUAT

La recomendación principal que se desprende de todo el análisis es **aprovechar la estacionalidad**, ya que sí se notan picos claros en ciertas etapas durante el año. Por esto, es recomendable que justo en esos momentos, o incluso un poco antes de que comiencen esos meses, se invierta una cantidad considerable de dinero en turismo, buscando que más personas elijan a Guatemala como su destino para vacacionar, o incluso promoviendo que los mismos guatemaltecos hagan turismo hacia otros países. Esto no solo incrementaría los ingresos para el gobierno, sino que también serviría como una fuente para generar empleo. Como sugerencia concreta, se podría incluir la contratación de influencers para promocionar algunos de los lugares turísticos de Guatemala.

Adicional a aprovechar la estacionalidad, también conviene tomar en cuenta las vías de ingreso según de dónde viene la persona y cuál es la vía que más se transita, de tal forma que las promociones se puedan orientar hacia ese enfoque y lleguen mejor al público correspondiente.

Asimismo, se recomienda identificar las regiones que se encuentran más en crisis, que en este caso son América del Norte y Europa, para tratar, en la medida de lo posible, de aligerar los precios y los boletos y de promocionar las salidas hacia esos destinos, buscando que estos puntos, que fueron los más afectados, puedan retomar poco a poco una buena cantidad de flujo de turismo.

Por último, cabe hacer una aclaración respecto al modelado. Debido a la pandemia y a la caída tan pronunciada que hubo en el turismo, que pasó prácticamente de un pico en 2019 a un valle cercano a cero en cuestión de meses, los modelos que aprenden la tendencia capturan ese comportamiento y no logran predecir bien lo que viene. Dado que después de la pandemia el turismo se fue retomando poco a poco, si realmente se necesitara construir un modelo, lo más recomendable sería entrenarlo tomando los datos de la etapa post-pandemia en adelante.

Conclusiones

El análisis muestra un turismo con tendencia de crecimiento clara hasta 2019, una estacionalidad anual marcada (más fuerte en los mercados lejanos como Europa y Norteamérica), y un impacto pandémico severo y desigual (Europa fue la más golpeada). En el modelado, aunque se ajustaron modelos SARIMA correctos según el análisis estadístico, el mejor desempeño de pronóstico lo obtuvo un modelo simple, lo que evidencia que un quiebre estructural como la pandemia limita la capacidad predictiva de los modelos que se apoyan en la tendencia. La conclusión práctica es que, para el escenario post-pandemia, las decisiones deben apoyarse en la evidencia reciente más que en proyecciones automáticas de largo plazo.